更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

数学建模|从实战到精通

——实战篇

第十八讲 – 聚类分析

主讲人：大师兄

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-介绍

➢ 什么是聚类

我们现在有一组UP主在B站发布各类视频时长所占总时长比例，假如你是B站的视频推荐算法工程师，为了更好的用户体验，请你制定适宜的策略，将这些UP主划分到不同类型，从而给用户推荐可能感兴趣的UP主.

序号	科技	女装	游戏	学习
小张	0.25	0.25	0.45	0.05
小王	0.33	0.22	0.11	0.34
小马	0.25	0.25	0.25	0.25
……				
大师兄	0.01	0.97	0.01	0.01

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-介绍

➢ 什么是聚类

先考虑最简单的情形，我们只关注游戏这一项，如果将这些样本点绘制在一个x轴上，那么接近的点就是一类.

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-介绍

➢ 什么是聚类

类似的，如果我们把科技和女装分别作为x轴和y轴，在xoy上把这些点标出来，相邻的点应该也是同一类.

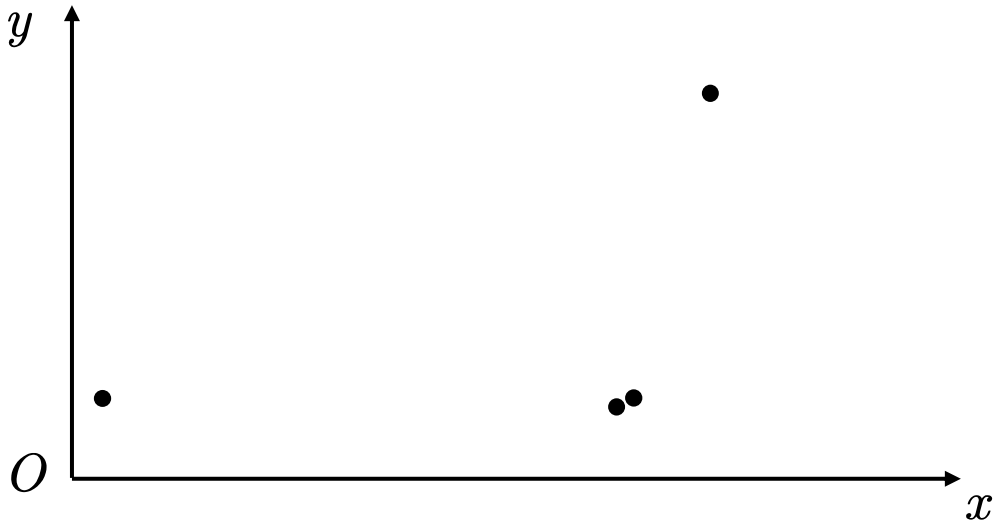

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-原理

➢ 分类准则-样本距离

绝对值距离 $d_1(x,y)=\sum_{k=1}^{p}|x_k-y_k|$

欧氏距离 $d_2(x,y)=\left[\sum_{k=1}^{p}|x_k-y_k|^2\right]^{\frac{1}{2}}$

Minkowski距离 $d_3(x,y)=\left[\sum_{k=1}^{p}|x_k-y_k|^q\right]^{\frac{1}{q}},\quad (q>0)$

切比雪夫距离 $d_4(x,y)=\max_{1\leqslant k\leqslant p}|x_k-y_k|$

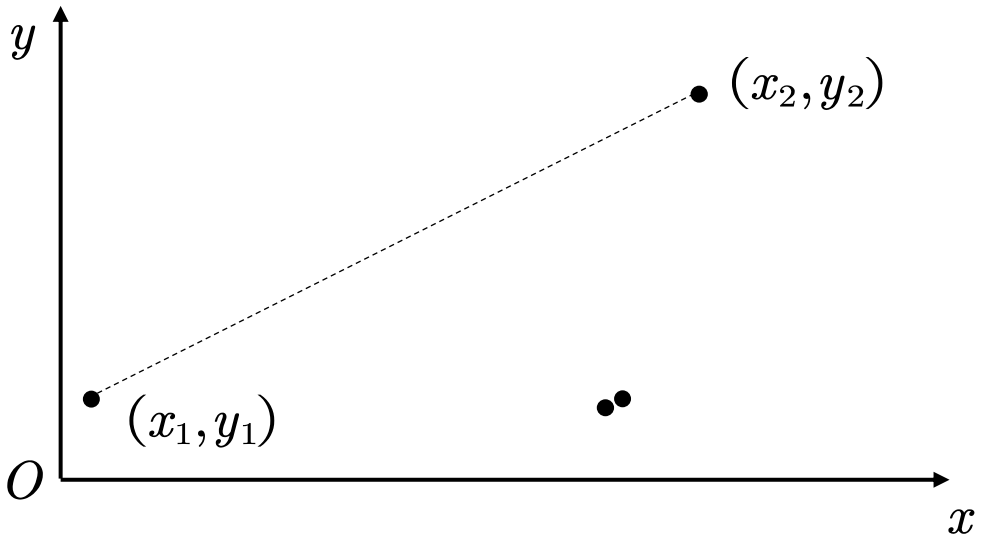

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-原理

➢ 指标之间的“距离”

相关系数：
$$\rho(X_i,X_j)=\frac{\sum_{k=1}^{p}(x_{ki}-\overline{x}_i)(x_{kj}-\overline{x}_j)}{\sqrt{\sum_{k=1}^{p}(x_{ki}-\overline{x}_i)^2\sum_{k=1}^{p}(x_{kj}-\overline{x}_j)^2}}$$

夹角余弦：
$$r(X_i,X_j)=\frac{\sum_{k=1}^{p}x_{ki}x_{kj}}{\sqrt{\sum_{k=1}^{p}x_{ki}^2\sum_{k=1}^{p}x_{kj}^2}}$$

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-原理

➢ 类与类的距离

1．由一个样品组成的类是最基本的类，如果每一类都由一个样品组成，那么样品间的距离就是类间距离.

2．如果某一类包含不止一个样品，那么就要确定类间距离，类间距离是基于样品间距离定义的.

记号：

1．G_p和G_q是两个类，$D(G_p,G_q)$是这两个类的距离.

2．$x_i \in G_p \quad x_j \in G_q$，$d(x_i,x_j)$是这两个样品的距离.

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-原理

➢ 最短距离法

$$D(G_p, G_q) = \min\ d(x_i, x_j)$$

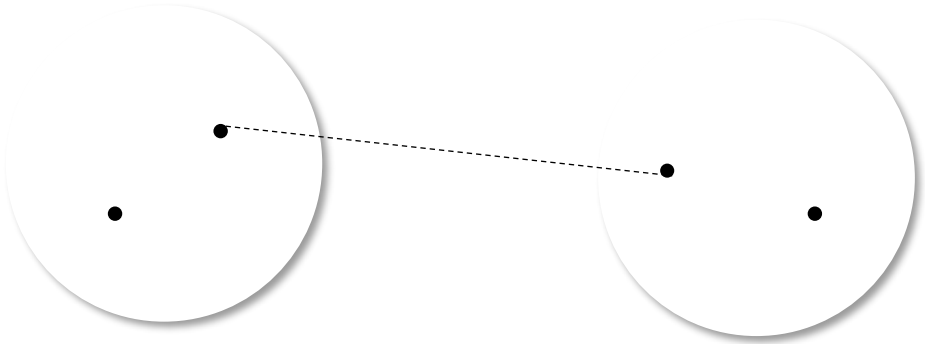

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

大师兄的知识库

聚类分析-原理

➢ 最长距离法

$$D(G_p, G_q) = \max\ d(x_i, x_j)$$

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-原理

➢ 组间平均连接法

$$D(G_p, G_q) = \frac{d_1 + d_2 + d_3 + d_4}{4}$$

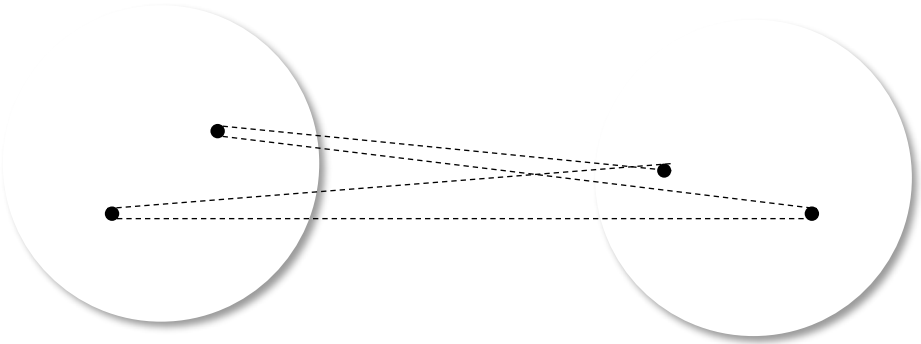

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-原理

➢ 组内平均连接法

$$D(G_p, G_q) = \frac{d_1 + d_2 + d_3 + d_4 + d_5 + d_6}{6}$$

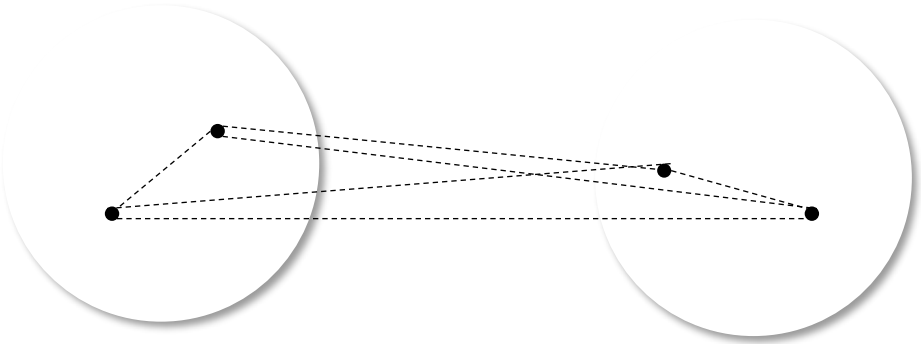

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-原理

➢ 重心法

$$D(G_p, G_q) = d(x_p, x_q)$$

$$\text{重心分别为} x_p = \frac{x_{p1} + x_{p2}}{2} \quad x_q = \frac{x_{q1} + x_{q2}}{2}$$

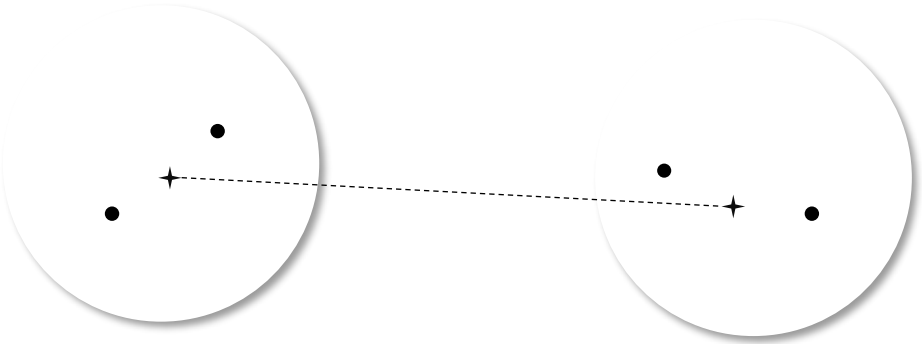

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 最短距离系统聚类法

	1	2	3	4
1	0			
2	0.46	0		
3	0.28	0.19	0	
4	0.62	0.99	0.83	0

D_0

采用最短距离法：$D(G_p, G_q) = \min\ d(x_i, x_j)$

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 最短距离系统聚类法

	1	2	3	4
1	0			
2	0.46	0		
3	0.28	0.19	0	
4	0.62	0.99	0.83	0

D_0

采用最短距离法：$D(G_p,G_q)=\min\ d(x_i,x_j)$

将每一个人看做一类，可知$D(G_2,G_3)$最小，故聚为一类，记作G_5.

计算新类到其他类的距离，得到新的距离矩阵D_1

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 最短距离系统聚类法

	1	2	3	4
1	0			
2	0.46	0		
3	0.28	0.19	0	
4	0.62	0.99	0.83	0

D_0

采用最短距离法：$D(G_p,G_q)=\min\ d(x_i,x_j)$

将每一个人看做一类，可知$D(G_2,G_3)$最小，故聚为一类，记作G_5.

计算新类到其他类的距离，得到新的距离矩阵D_1

$$D(G_5,G_1)=\min\{D(G_2,G_1),D(G_3,G_1)\}=\min\{0.46,0.28\}=0.28.$$

$$D(G_5,G_4)=\min\{D(G_2,G_4),D(G_3,G_4)\}=\min\{0.99,0.83\}=0.83.$$

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 最短距离系统聚类法

	1	4	5
1	0		
4	0.62	0	
5	0.28	0.83	0

D_1

采用最短距离法：$D(G_p,G_q)=\min\ d(x_i,x_j)$

将每一个人看做一类，可知$D(G_2,G_3)$最小，故聚为一类，记作G_5.

计算新类到其他类的距离，得到新的距离矩阵D_1

$$D(G_5,G_1)=\min\{D(G_2,G_1),D(G_3,G_1)\}=\min\{0.46,0.28\}=0.28.$$

$$D(G_5,G_4)=\min\{D(G_2,G_4),D(G_3,G_4)\}=\min\{0.99,0.83\}=0.83.$$

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 最短距离系统聚类法

	1	4	5
1	0		
4	0.62	0	
5	0.28	0.83	0

D_1

同理，在其中又找到了最小距离，所以把G_1和G_5分为一类，记为G_6

计算新类到其他类的距离

$$D(G_6,G_4)=\min\{D(G_1,G_4),D(G_5,G_4)\}=\min\{0.28,0.83\}=0.28.$$

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 最短距离系统聚类法

	4	6
4	0	
6	0.28	0

D_2

最后将G_4和G_6聚为一类

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 聚类的谱系图

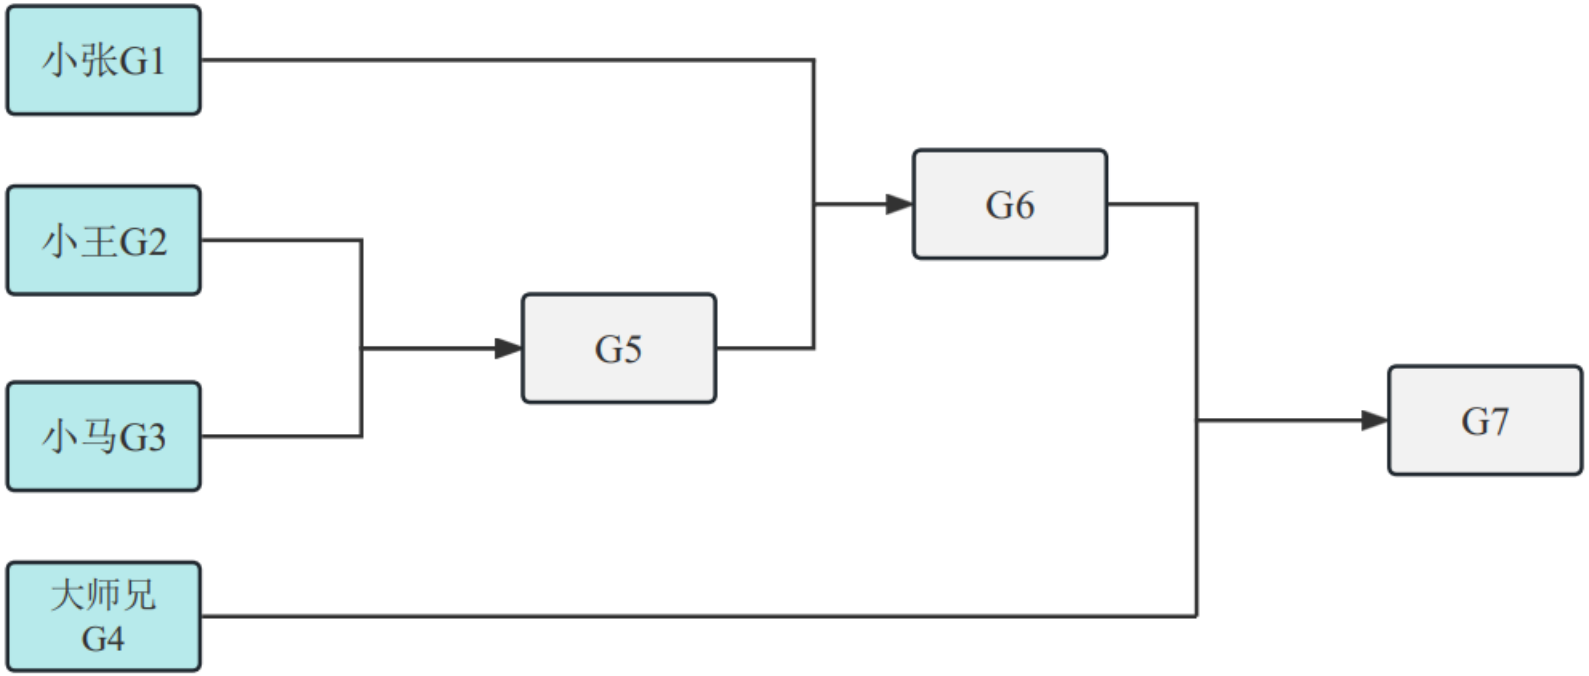

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 聚类的谱系图

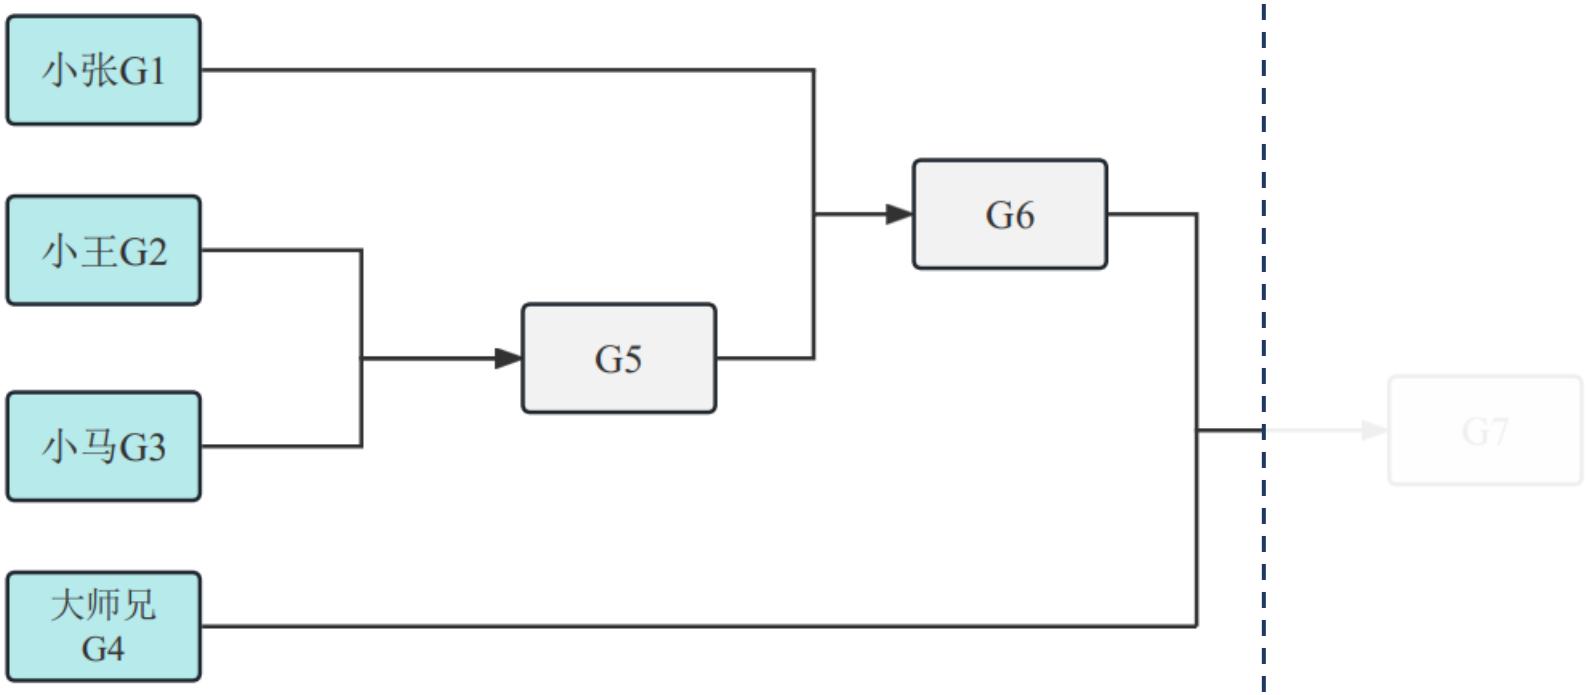

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 聚类的谱系图

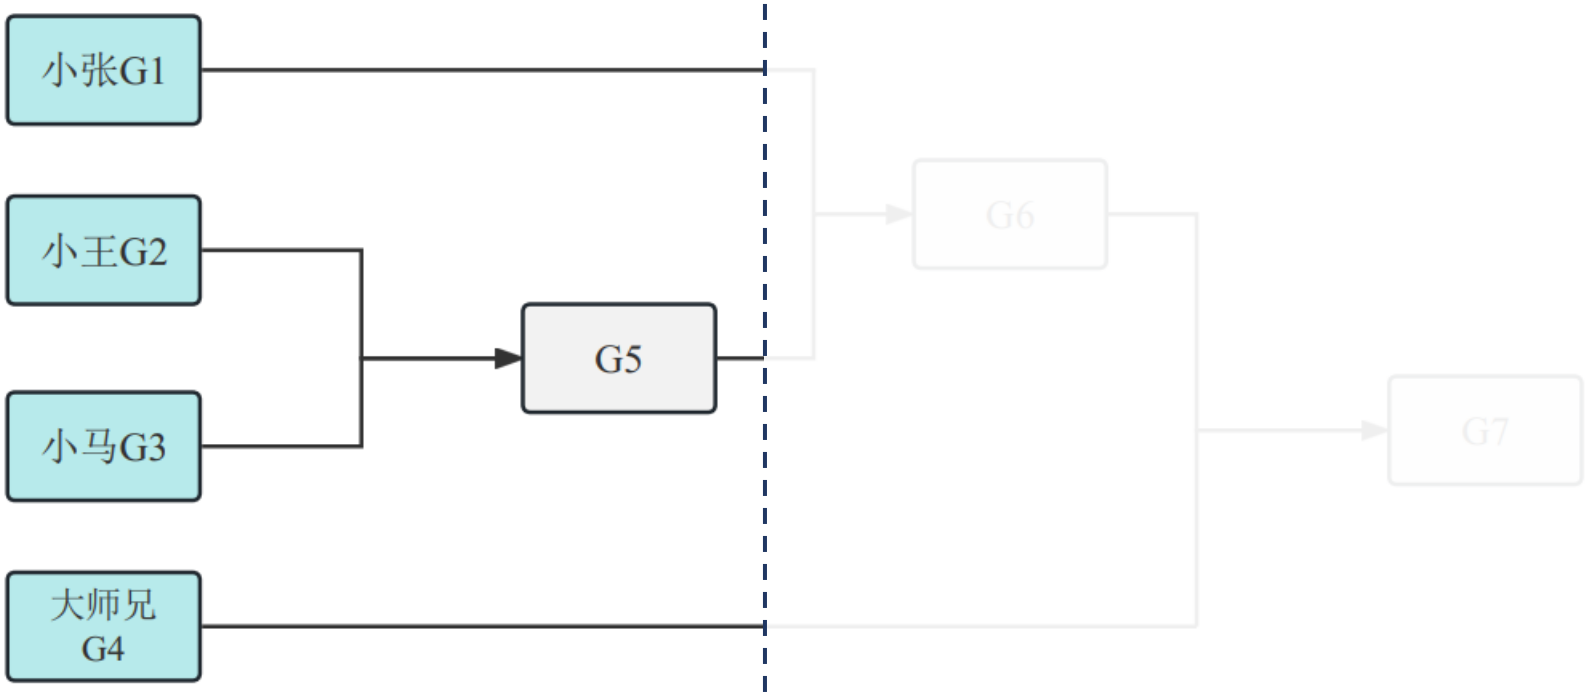

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 聚类的谱系图

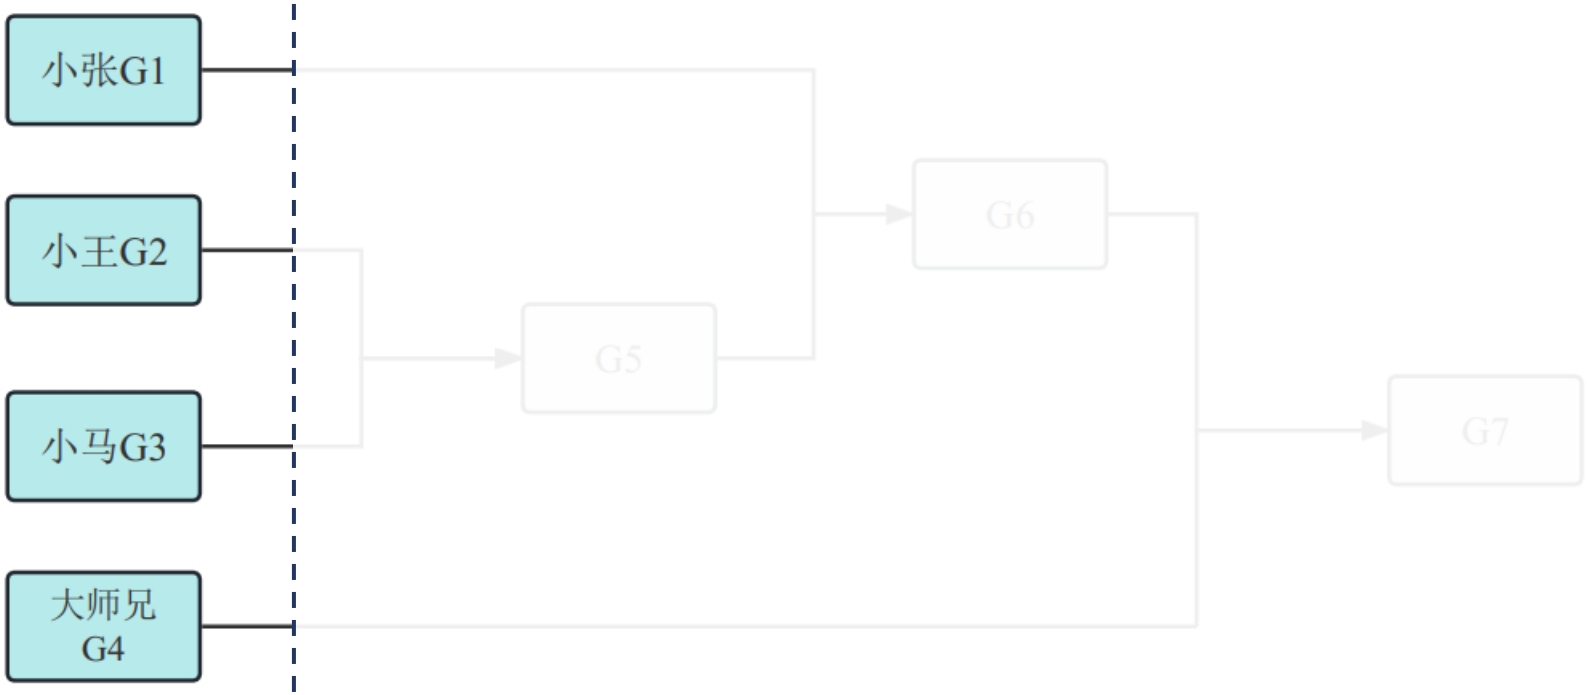

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ Kmeans聚类算法

在给定n值和k个初始类簇中心点的情况下，把每个点(亦即数据记录)分到离其最近的类簇中心点所代表的类簇中，所有点分配完毕之后，根据一个类簇内的所有点重新计算该类簇的中心点(取平均值)，然后再迭代的进行分配点和更新类簇中心点的步骤，直至类簇中心点的变化很小，或者达到指定的迭代次数。

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ Kmeans聚类算法

假定给定数据样本X,包含了n个对象$X=\{X_1,X_2,X_3,\ldots,X_n\}$,其中每个对象都具有$m$个维度的属性。

Kmeans算法的目标是将n个对象依据对象间的相似性聚集到指定的k个类簇中，每个对象属于且仅属于一个其到类策中心距离最小的类簇中。

对于Kmeans,首先需要初始化k个聚类中心$\{C_1,C_2,C_3,\ldots,C_k\}$, $1<k\le n$,然后通过计算每一个对象到每一个聚类中心的欧式距离，如下式所示$dis(X_i,C_j)=\sqrt{\sum_{t=1}^{m}(X_{it}-C_{jt})^2}$

然后再用新加入的点更新簇中心：$C_t=\dfrac{\sum_{X_i\in S_l}X_i}{|S_l|}$

其实这就是传说中的无监督机器学习

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ Kmeans++聚类算法

Kmeans对初值和孤立点数据敏感，有时候聚类效果并不理想，所以我们改进之后就是Kmeans＋＋算法

它的思想是初始的聚类中心之间的相互距离要尽可能的远.

步骤一：随机选取一个样本作为第一个聚类中心；

步骤二：计算每个样本与当前已有聚类中心的最短距离(即与最近一个聚类中心的距离)，这个值越大，表示被选取作为聚类中心的概率较大，最后，用轮盘法(依据概率大小来进行抽选)选出下一个聚类中心；

步骤三:重复步骤二，直到选出K个聚类中心，然后执行Kmeans算法.

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ DBSCAN聚类算法

DBSCAN一种基于密度的聚类方法，聚类前不需要预先指定聚类的个数，生成的簇的个数不定(和数据有关) 。该算法利用基于密度的聚类的概念，即要求聚类空间中的一定区域内所包含对象(点或其他空间对象) 的数目不小于某一给定闯值。该方法能在具有噪声的空间数据库中发现任意形状的簇，可将密度足够大的相邻区域连接，能有效处理异常数据。

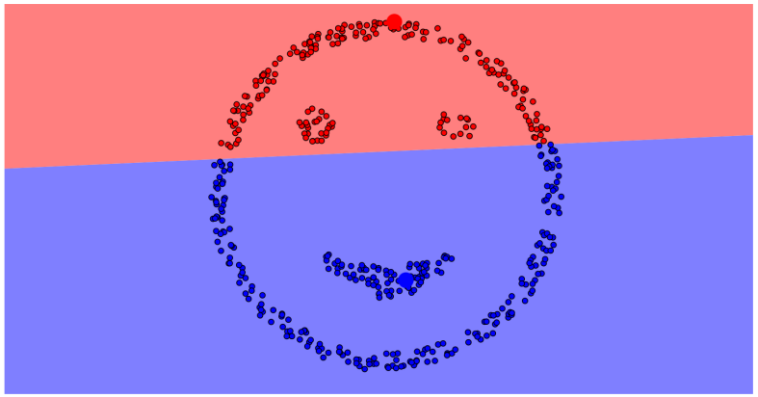

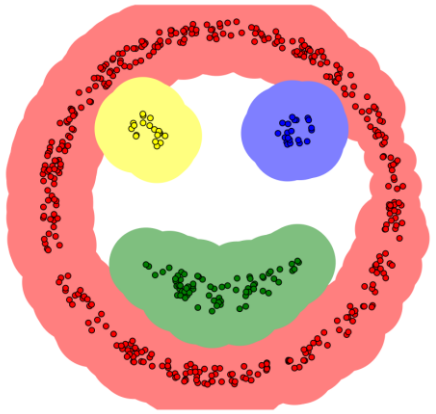

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ DBSCAN聚类算法

Epsilon：区域半径

minPoints：簇内最小点个数

DBSCAN算法将数据点分为三类:

核心点: 在半径Eps内含有不少于MinPts数目的点·

边界点: 在半径Eps内点的数量小于MinPts，但是落在核心点的邻域内

噪音点: 既不是核心点也不是边界点的点

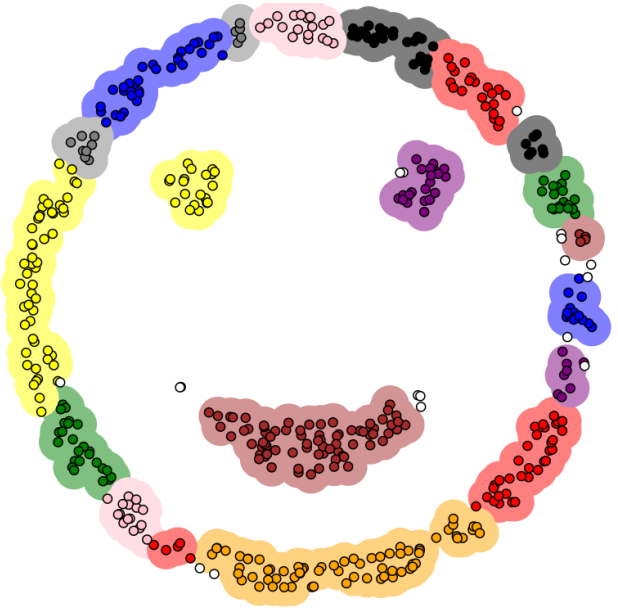

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-常见算法

➢ 作业

请选取一个聚类方法，将上机篇的例题撰写成一篇论文

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

大师兄的知识库

Part 2

上机演示

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-应用

➢ 数据集介绍

近年来，我国普通高等教育得到了迅速发展，为国家培养了大批人才。但由于我国各地区经济发展水平不均衡，加之高等院校原有布局使各地区高等教育发展的起点不一致因而各地区普通高等教育的发展水平存在一定的差异，不同的地区具有不同的特点。对我国各地区普通高等教育的发展状况进行聚类分析，明确各类地区普通高等教育发展状况的差异与特点，有利于管理和决策部门从宏观上把握我国普通高等教育的整体发展现状，分类制定相关政策，更好地指导和规划我国高教事业的整体健康发展。

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

大师兄的知识库

聚类分析-应用

➢ 数据集介绍

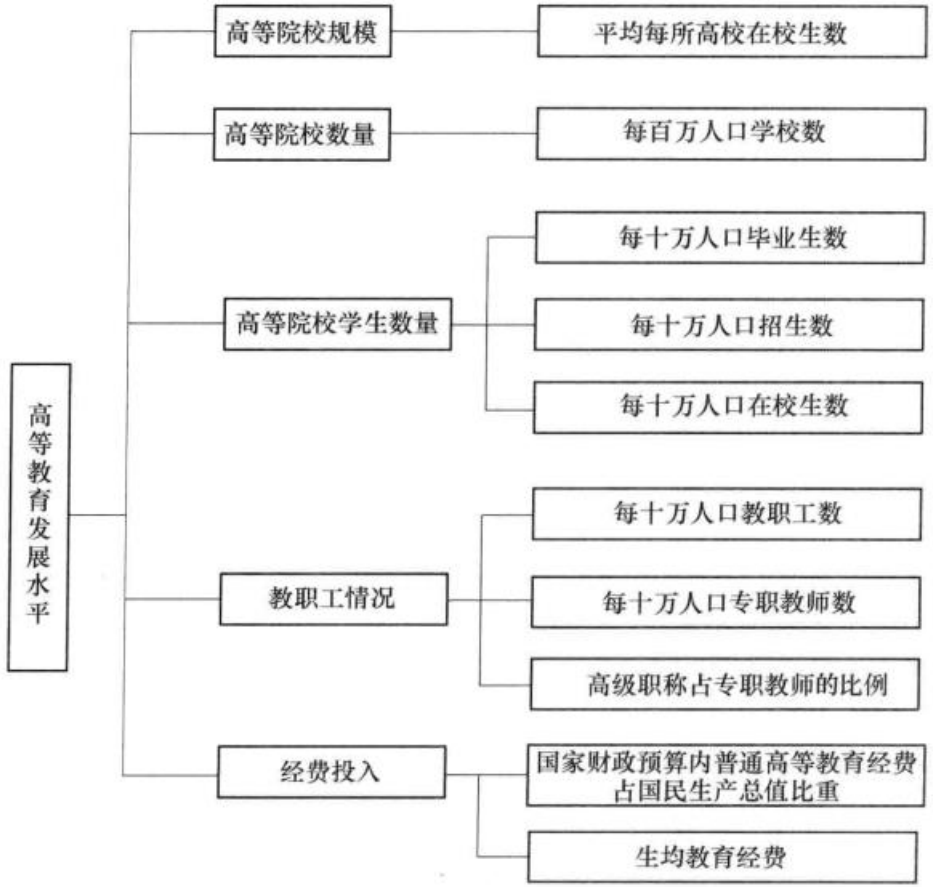

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-应用

➢ 聚类的注意事项-数据预处理

正向化+标准化

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

聚类分析-应用

➢ 聚类K值的选取-肘部法则

假设一共将n个样本划分到K个类中$(K \le n-1$,即至少有一类中有两个元素$)$用C_k表示第k个类$(k=1,2,\cdots,K)$，且该类重心的位置记为u_k那么第k个类的畸变程度为：$\sum_{i \in C_k} |x_i - u_k|^2$

再计算所有大类的总畸变程度：$J = \sum_{k=1}^{K} \sum_{i \in C_k} |x_i - u_k|^2$，这里的$J$就是聚合系数，我们就要关注聚合系数$J$和聚类类别$K$的关系.

聚合系数曲线突然变平缓时对应的k就是我们所要取的值

当然你也可以多试几次，
选取分类效果较好的那个

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407

更多优质资源欢迎关注“大师兄的知识库”微信公众号，回复“数学建模”可获取本套课程课件和代码及所需软件安装包

大师兄的知识库

聚类分析-应用

➢ 聚类K值的选取-肘部法则

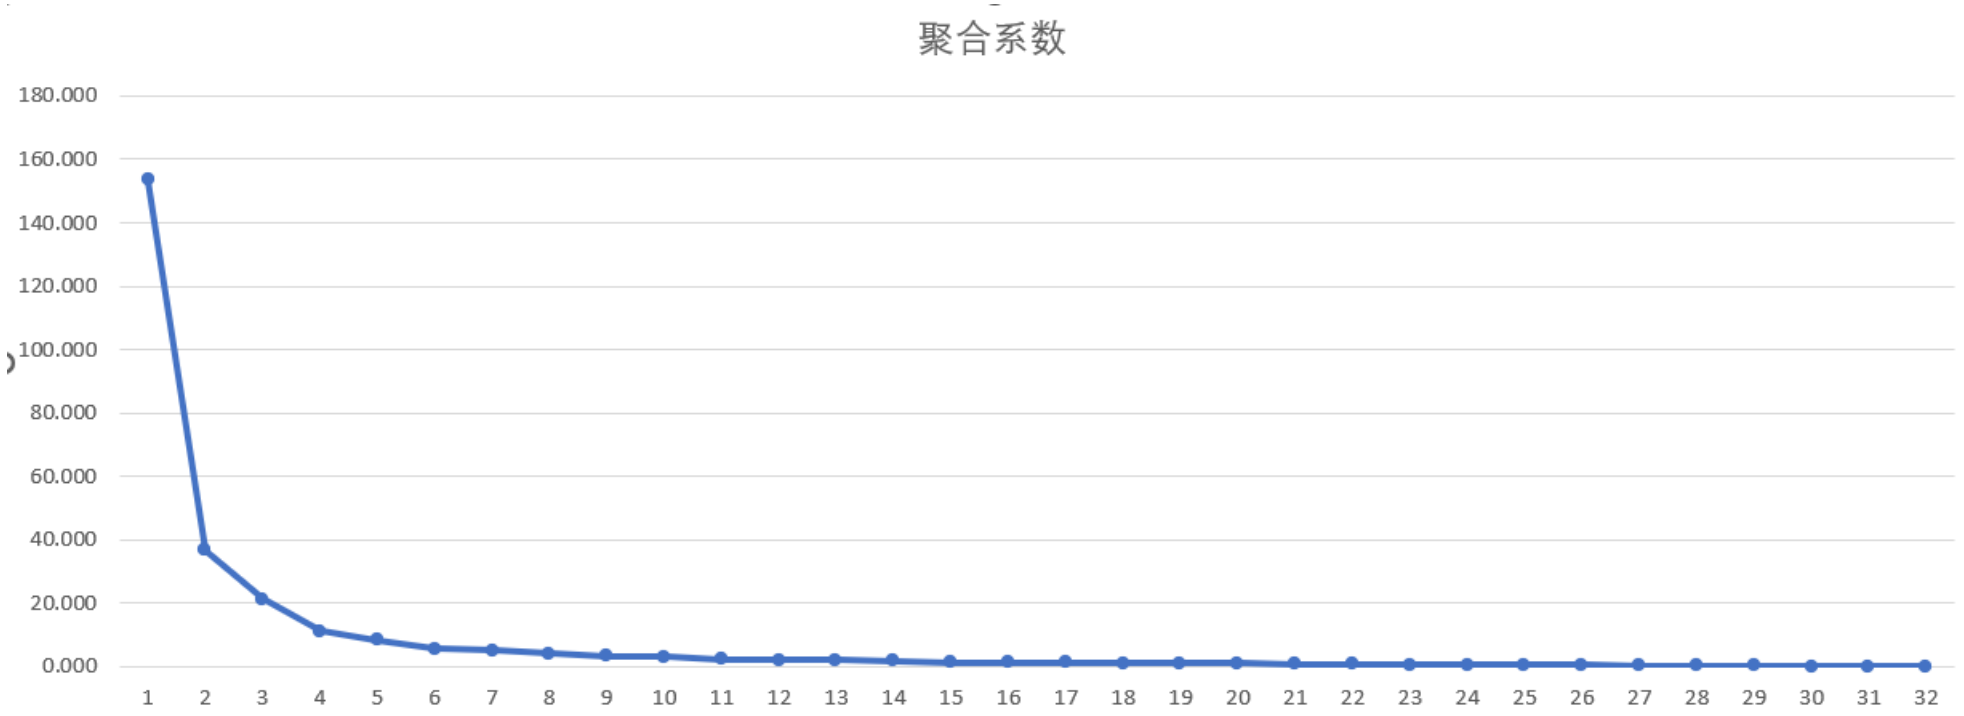

微信公众号：大师兄的知识库　微博：花果山没有眼泪　QQ交流群：653489407